

Pemanfaatan *Explainable AI* pada model optimal XGBoost dengan algoritma *Tree-structured Parzen Estimator* untuk Mendekonstruksi Penyebab Multifaktorial Kasus *Stunting* dengan *framework* Interpretabilitas Berbasis *SHAP*

Aryanto^{1*}, Radian J. Situmeang¹, Ebenhaizer Liunokas²

^{1*} Matematika/Statistika, Universitas Cenderawasih,

² Matematika/Matematika, Universitas Timor,

aryanto.dandan@gmail.com

Submitted hh-bb-20xx	Revised hh-bb-20xx	Accepted hh-bb-20xx	Online hh-bb-20xx
-------------------------	-----------------------	------------------------	----------------------

ABSTRACT

Analysis and modeling of stunting risk in toddlers in the Mamberamo Raya Regency, Papua, in 2024 using an XGBoost model optimized with the Tree-structured Parzen Estimator algorithm achieved an accuracy of 88.52%. The model demonstrated excellent capability in identifying non-stunting cases (recall 96.5%) but still misclassified 18.5% of stunting cases. This study revealed that three main variables such as Malnutrition Level, relevant district health policies and service area, and Exclusive Breastfeeding are the most dominant predictors based on Explainable AI (SHAP) analysis of their complex interactions. Malnutrition Level was the strongest contributor, while variables related to difficulties in accessing healthcare services played a significant role both structurally in building the XGBoost model and through their interactions with nutritional factors. These findings emphasize the importance of a multidimensional approach combining nutritional interventions and improved healthcare accessibility as a priority strategy to reduce stunting, considering the local context and the interplay among risk factors.

Keyword: Stunting, Malnutrition, XGBoost, Classification, Explainable AI

ABSTRAK


Analisis dan pemodelan risiko stunting pada balita di wilayah Kabupaten Mamberamo Raya, Papua tahun 2024 menggunakan model XGBoost yang dioptimasi dengan algoritma *Tree-structured Parzen Estimator* menghasilkan akurasi sebesar 88,52%, dengan kemampuan identifikasi kasus tidak stunting yang sangat baik (sensitifitas mencapai 96,5%) namun masih kekeliruan dalam mendeteksi 18,5% kasus stunting. Studi ini mengungkapkan bahwa tiga variabel utama yaitu Tingkat Malnutrisi, kebijakan dan area pelayanan distrik terkait, serta Pemberian ASI Eksklusif, merupakan prediktor paling dominan berdasarkan analisis Explainable AI (SHAP) terhadap interaksi kompleks di antara ketiganya. Tingkat Malnutrisi menjadi kontributor terkuat, sementara variabel yang terkait dengan kesulitan akses layanan kesehatan berperan signifikan baik secara struktural dalam membangun model XGBoost maupun melalui interaksinya dengan faktor gizi. Temuan ini menekankan pentingnya pendekatan multidimensi yang memadukan intervensi perbaikan gizi dan peningkatan aksesibilitas layanan kesehatan sebagai strategi prioritas penurunan stunting, dengan memperhatikan konteks lokal dan interaksi antar faktor risiko.

Kata Kunci: Stunting, Malnutrisi, XGBoost, Klasifikasi, Explainable AI

PENDAHULUAN

Provinsi Papua merupakan salah satu wilayah dengan tantangan penanganan kasus stunting yang paling kompleks dan sulit di Indonesia. Berdasarkan hasil survey status gizi Indonesia tahun 2022, prevalensi stunting di Papua sebesar 34.6%, berada di atas rata-rata nasional (21.6%) dan urutan kedua tertinggi setelah Sulawesi Barat (Kemenkes, 2022). Secara khusus untuk Kabupaten Mamberamo Raya (KMR) di provinsi Papua, tercatat sebagai penyumbang terbesar status gizi buruk balita sebesar 40.0% berdasarkan survey Kesehatan Indonesia (SKI, 2023). Untuk diketahui, SKI 2023 mengukur 1,536 anak dan 28.6% diantaranya menderita gangguan stunting. Selain itu, daerah KMR memiliki karakteristik

geografis unik yang terdiri dari pegunungan dan dataran rendah. Sebagian besar wilayahnya merupakan daerah sulit diakses sehingga berimplikasi pada terbatasnya jangkauan layanan kesehatan, distribusi pangan bergizi, serta ketersediaan infrastruktur dasar seperti akses air bersih dan jamban sehat. Kondisi ini diduga kuat menjadi faktor risiko signifikan yang berkontribusi terhadap tingginya angka stunting di kawasan KMR.



Gambar 3.1 Peta Administrasi Kabupaten Mamberamo Raya, Papua

Menurut CenderawasihPos (2024), Pemerintah KMR saat ini mencatat angka prevalensi stunting tertinggi di Papua memicu respons cepat dari Dinas Pemberdayaan Perempuan, Perlindungan Anak, Pengendalian Penduduk, dan Keluarga Berencana (DP3AP2KB) Kabupaten Mamberamo Raya untuk meluncurkan program inovatif bernama Gerakan Orang Tua Asuh Cegah Stunting (Genting) sebagai langkah penanganan terhadap kasus yang tinggi tersebut. Program Genting ini difokuskan pada upaya intervensi langsung terhadap anak-anak yang berisiko atau sudah mengalami stunting, dengan melibatkan peran masyarakat dan pihak terkait sebagai orang tua asuh. Langkah ini menunjukkan keseriusan Pemerintah KMR dalam mengatasi masalah gizi kronis yang menjadi prioritas pembangunan daerah. Langkah ini menunjukkan keseriusan Pemerintah KMR untuk menurunkan prevalensi balita stunting namun belum memperhatikan karakteristik indikator terjadinya kasus balita stunting.

Penelitian sebelumnya mengenai faktor-faktor terkait stunting di Papua New Guinea (PNG), meskipun telah menguji variabel seperti kekayaan, pendidikan ibu, dan imunisasi, seringkali dibatasi oleh data yang tidak representatif secara nasional dan faktor ketepatan waktu yakni menggunakan data representatif nasional dari survei lama seperti PNG HIES 2009–2010, sehingga membatasi generalisasi temuan mereka. Untuk meningkatkan kinerja prediksi, pendekatan Machine Learning (ML) seperti Random Forests dan XGBoost kini lebih diunggulkan daripada model statistik klasik karena kemampuannya menangani hubungan nonlinier, didukung oleh bukti dari negara-negara lain. Dalam konteks ini, penggunaan teknik Feature Selection (FS) menjadi esensial untuk mengoptimalkan algoritma ML dengan menyingkirkan fitur yang redundan. Oleh karena tingginya prevalensi stunting


yang masih menjadi masalah di PNG, penelitian yang menjadi subjek paragraf ini bertujuan mengaplikasikan teknik FS bersama algoritma ML pada data nasional 2016–2018 PNG DHS untuk mengidentifikasi model prediksi stunting terbaik dan fitur-fitur yang paling berpengaruh, guna memberikan bukti ilmiah yang kuat bagi pembuat kebijakan PNG untuk merancang intervensi yang lebih tertarget (Shen et al., 2023).

Penelitian terbaru oleh Wicaksono et al. (2025) berjudul Data Analysis and Explainable Machine Learning for Stunting Prediction berupaya mengatasi tantangan deteksi dini stunting di negara berpendapatan rendah dan menengah dengan mengembangkan dan mengevaluasi kerangka kerja Explainable Machine Learning (XAI). Penelitian ini menggunakan data dari 40,071 balita di Kabupaten Jeneponto, Sulawesi Selatan, Indonesia, dengan memanfaatkan fitur sederhana seperti usia dalam bulan, jenis kelamin, berat, dan tinggi. Setelah membandingkan delapan algoritma ML, ditemukan bahwa model XGBoost memberikan kinerja prediksi tertinggi dengan akurasi mencapai 97.57%. Pada penelitian lainnya, XGBoost menonjol dalam hal metrik presisi dan recall pada data stunting di kasus balita di Zambia (Chilyabanyama, 2022). Kontribusi penting penelitian ini terletak pada integrasi XAI menggunakan SHAP (SHapley Additive exPlanations), yang mengungkapkan bahwa tinggi badan adalah prediktor paling berpengaruh, diikuti oleh usia dan jenis kelamin. Kerangka kerja ini tidak hanya meningkatkan akurasi dan transparansi deteksi stunting dini tetapi juga menyediakan insight yang dapat ditindaklanjuti, baik secara global maupun lokal, untuk memperkuat sistem surveilans gizi.

Penelitian ini mengusulkan kerangka kerja berbasis data (data-driven framework) untuk prediksi stunting dini pada balita berusia 0 hingga 59 bulan di wilayah KMR menggunakan Explainable Machine Learning (XAI). Sehingga dapat disampaikan bahwa penelitian ini ditujukan untuk (i) memprediksi status gizi balita menggunakan model eXtreme Gradient Boosting (XGBoost) dan, (ii) menghasilkan interpretasi data melalui analisis fitur-fitur (prediktor) yang berpengaruh dan memperjelas prediksi individual untuk mendukung pengambilan keputusan kesehatan masyarakat yang terinformasi dan intervensi yang ditargetkan di lingkungan terbatas sumber daya.

METODE

Penelitian yang digunakan adalah analisis kuantitatif dengan bantuan model machine learning. Diagram alir pengerjaannya dapat dilihat pada grafik 2.1.




Grafik 2.1 Diagram alir pengerjaan

Dataset

Data yang digunakan pada penelitian ini bersumber dari hasil survey kesehatan yang dilakukan pada setiap wilayah kerja Puskesmas di distrik-distrik di KMR dan telah diinput pada database Dinas Kesehatan KMR bulan Agustus tahun 2024. Total data anak yang diperoleh sebanyak 607 balita. Data dibagi menjadi dua set: data latih (training set) sebanyak 485 sampel (80%) dan data uji (testing set) sebanyak 122 sampel (20%).

Desain Penelitian

Penelitian observasional ini menggunakan desain kasus kontrol untuk mengetahui faktor yang memengaruhi stunting pada balita serta mengetahui besar risiko (nilai odds ratio) dari masing masing faktor. Penelitian menggunakan data yang dikumpulkan oleh Dinas Kesehatan KMR selama 3 (tiga) bulan (Juni - Agustus 2024) di wilayah kerja Puskesmas pada distrik - distrik di KMR.



Grafik 2.2 Banyaknya data pada setiap distrik di KMR

Secara umum, para responden terdiri dari ibu/wali dari anak tersebut. Untuk anak, diambil anak usia kurang dari sama dengan 59 bulan. Responden diwawancari langsung secara lisan dan petugas mengisi kuesioner yang tersedia berdasarkan jawaban responden. Hasil survei tersebut dikerucutkan menjadi beberapa faktor-faktor kunci yakni:

- 1) Jenis Kelamin merupakan ciri biologis dari anak balita yang bersangkutan yakni laki-laki (1) dan perempuan (0).
- 2) Pemberian ASI dan MP ASI diukur dari riwayat memberikan ASI dan MP ASI dari mulai lahir sampai saat dilaksanakan penelitian terdiri dari beberapa pertanyaan tentang ASI Eksklusif, usia pemberian, jenis dan tahapan makanan pendamping ASI (MP-ASI) kemudian dari total skor dilakukan uji normalitas untuk dikategorikan menjadi baik (1) dan kurang baik (0) (Kusumawati, 2015). Untuk variabel ini dalam data diwakili nama 'ASI Eksklusif'.
- 3) Terdapat kondisi dimana racun dari rokok dari kebiasaan salah satu anggota keluarga, terhirup balita menyebabkan tinggi dan berat badan balita tidak berkembang sama sekali. Juga terdapat kejadian penyakit infeksi saluran pernapasan akut (ISPA), diare, atau campak selama penelitian pada balita. Variabel ini disebut sebagai 'Kebiasaan merokok dalam keluarga'. Jika terdapat minimal terdapat satu anggota keluarga yang memiliki kebiasaan merokok, variabel ini akan bernilai 1 dan sebaliknya, akan bernilai nol (0).
- 4) Variabel "Akses ke air bersih" dipilih dalam penelitian ini karena merupakan faktor krusial yang sangat memengaruhi kesehatan dan pertumbuhan anak, termasuk risiko stunting. Akses ke air bersih berperan penting dalam mencegah penyakit infeksi saluran pencernaan yang dapat menghambat penyerapan gizi dan menyebabkan gangguan pertumbuhan pada anak. Pengukuran

variabel ini membantu mengidentifikasi hubungan antara ketersediaan air bersih dengan jarak kurang dari 200 meter dari tempat tinggal balita dengan kejadian stunting, sebagai salah satu indikator determinan lingkungan yang memengaruhi status gizi. Dalam data penelitian, variabel ini dikodekan secara biner dengan nilai 1 menunjukkan adanya akses ke air bersih, dan nilai 0 menunjukkan sebaliknya.

- 5) Terdapat variabel "jamban sehat" karena diketahui bahwa fasilitas sanitasi yang baik merupakan salah satu penentu utama kualitas lingkungan hidup yang berpengaruh langsung terhadap kesehatan anak. Ketersediaan jamban sehat membantu mengurangi risiko penyebaran penyakit infeksi akibat kontaminasi tinja yang dapat menyebabkan infeksi dan gangguan pencernaan, faktor yang berkontribusi pada terjadinya stunting. Variabel ini diukur secara biner dengan nilai 1 menunjukkan keberadaan jamban sehat di tempat tinggal, dan nilai 0 menunjukkan tidak adanya fasilitas tersebut, sehingga memudahkan evaluasi hubungan antara sanitasi dan pertumbuhan anak dalam konteks pencegahan stunting.
- 6) Beberapa penilaian terhadap akses ke rumah juga dibawa kedalam penilaian pada survey yang dilakukan. Hal ini disimpulkan pada variabel akses lokasi rumah yang dibuat dalam bentuk biner. Misalnya terdapat rumah yang dekat dengan jalan raya dan dapat diakses dengan kendaraan, diberikan nilai satu (1). Sedangkan jika suatu tempat tinggal responden yang cukup sulit untuk diakses, misalnya perlu berjalan kaki selama beberapa saat, lokasi rumah di atas bukit, atau adanya hambatan lain yang menyulitkan untuk sampai pada rumah tersebut, diberikan nilai nol (0).
- 7) Penelitian ini juga mengukur status gizi pada balita. Tujuannya adalah sebagai indikator kuantitatif untuk menilai derajat keparahan kondisi gizi anak, yang berperan penting dalam memahami spektrum risiko stunting. Petugas kesehatan di puskesmas yang melakukan wawancara terhadap Ibu dan anak mengukur tingkat status gizi ini melalui penilaian antropometri, seperti pengukuran berat badan, tinggi badan, dan lingkar lengan atas, kemudian membandingkan hasilnya dengan standar pertumbuhan WHO untuk menentukan kategori status gizi anak (Kusumawati, 2015). Hasilnya berupa nilai skala yakni dari 0 hingga 6 yang mencerminkan tingkat status gizi, dengan angka 6 menunjukkan kondisi gizi yang sangat buruk, sehingga memungkinkan identifikasi anak-anak yang paling rentan terhadap gangguan pertumbuhan.
- 8) Dan satu variabel terakhir adalah variabel penilaian stunting. Penilaian ini didasarkan pertimbangan dari petugas kesehatan dan/atau dokter. Variabel ini berfungsi sebagai indikator klinis langsung atas kondisi stunting pada anak responden. Variabel ini dikodekan secara biner, di mana nilai 1 menunjukkan bahwa anak tersebut dinyatakan mengalami stunting berdasarkan evaluasi dan pemeriksaan oleh tenaga kesehatan profesional, sedangkan nilai 0 menandakan tidak adanya stunting. Penilaian ini penting karena menggabungkan aspek medis yang mempertimbangkan kondisi fisik dan perkembangan anak secara menyeluruh, sehingga dapat melengkapi data kuantitatif serta memberikan validasi terhadap status pertumbuhan anak dalam konteks penelitian stunting (Muhdar, 2025).

Algoritma Extreme Gradient Boosting

XGBoost (*eXtreme Gradient Boosting*) adalah algoritma machine learning yang menggabungkan konsep gradient boosting dengan pohon keputusan secara efisien dan cepat. Algoritma XGBoost merupakan pengembangan dari gradient boosting yang diusulkan oleh Dr. Tianqi Chen dari University of Washington pada tahun 2014 (Yulianti, 2022). Algoritma ini bekerja dengan cara membangun model prediksi sebagai penjumlahan dari beberapa pohon keputusan (decision trees) yang lemah, di mana setiap pohon baru berusaha memperbaiki kesalahan dari pohon-pohon sebelumnya. Secara matematis, prediksi untuk satu data x_i dinyatakan sebagai

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i),$$

di mana K adalah jumlah pohon, dan f_k adalah fungsi prediksi pohon ke- k . Pohon-pohon ini berasal dari ruang fungsi yang dikenal sebagai $\mathcal{F}$, yang membuat model ini fleksibel dan kuat dalam melakukan aproksimasi fungsi (Tribuana, 2025). Dalam pelatihan model, XGBoost meminimalkan fungsi objektif yang terdiri dari dua bagian, yaitu fungsi loss yang mengukur ketidaksesuaian antara prediksi $\hat{y}_i$ dan

nilai sebenarnya y_i , serta fungsi regularisasi yang mengontrol kompleksitas model agar tidak terjadi overfitting (Chen, 2025). Fungsi objektif ini dapat dirumuskan sebagai

$$obj(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

di mana l adalah fungsi loss yang diferensiabel dan konveks, serta Ω adalah fungsi penalti atas kompleksitas pohon, misalnya jumlah daun dan bobot daun pohon ke- k . Model XGBoost dilatih secara iteratif terbatas (m) dengan menambahkan satu pohon pada setiap langkah untuk mengoreksi residual dari model sebelumnya, sehingga pada iterasi ke- m model diperbaharui sebagai

$$F_m(x) = F_{m-1}(x) + f_m(x)$$

yang membuat algoritma ini sangat efektif dan efisien dalam menangani berbagai masalah regresi, klasifikasi, dan ranking.

Hyperparameter dengan Optuna

Optuna adalah sebuah framework optimasi hyperparameter otomatis yang menggunakan metode *_Bayesian optimization_* secara spesifik yaitu *Tree-structured Parzen Estimator* (TPE) untuk mencari konfigurasi hyperparameter terbaik secara efisien. Hyperparameter merupakan parameter eksternal model seperti laju pembelajaran, jumlah pohon, atau kedalaman maksimum pohon pada XGBoost yang tidak dipelajari langsung selama proses training. Optuna mengoptimalkan hyperparameter dengan meminimalkan fungsi objektif $f(\theta)$, dimana θ merepresentasikan set hyperparameter. Secara matematis, optimasi model dapat dilakukan dengan mencari $\hat{\theta}$ sehingga

$$\hat{\theta} = \arg \min_{\theta} f(\theta)$$

di mana θ umumnya berupa nilai loss atau error model pada data validasi (Akiba, 2019).

Penggunaan TPE pada Optuna yang memodelkan distribusi probabilitas untuk menilai nilai hyperparameter yang menjanjikan berdasarkan hasil percobaan sebelumnya. Proses ini merupakan pencarian bertahap dengan menyeimbangkan eksplorasi dan eksploitasi melalui fungsi akuisisi (Bergstra, 2013). Dengan pendekatan ini, Optuna mampu menemukan ragam kombinasi hyperparameter yang dapat meningkatkan performa model secara signifikan tanpa harus menguji semua kemungkinan secara eksponensial.

Dalam konteks XGBoost, hyperparameter penting yang dioptimalkan melalui Optuna mencakup parameter seperti learning rate η , jumlah pohon n_{tree} , dan kedalaman maksimum pohon d_{max} . Fungsi objektif yang diminimasi bisa dituliskan:

$$J = \sum_{i=1}^n l(y_i, \hat{y}_i(\theta)) + \Omega(\theta)$$


di mana $l(\cdot)$ adalah fungsi loss pada data, dan $\Omega(\theta)$ adalah regularisasi untuk menghindari overfitting. Dengan demikian, Optuna membantu mencari nilai $\theta = \{\eta, \eta_{tree}, d_{max}, \dots$ terbaik agar model dapat mencapai nilai J minimal dan performa maksimal.

HASIL DAN PEMBAHASAN

Data Analisis


Data yang telah dikumpulkan pada KMR tahun 2024 khususnya variabel Stunting dapat memiliki bias judgement dari para ahli kesehatan. Untuk itu, kami menjadikan variabel target (yang akan diprediksi) adalah variabel stunting yang berbentuk biner. Sugihartono (2025) menyampaikan bahwa kelas tak seimbang (*class imbalance*) memiliki kisaran perbandingan 1:3 hingga 1:6 ke bawah. Mayoritas populasi

memiliki status stunting (ditandai dengan '1') dibandingkan dengan yang tidak stunting (ditandai dengan '0'). Grafik 5.1 menunjukkan bahwa 54.0% dari total populasi mengalami stunting, yang secara jumlah setara dengan 328 kasus. Sementara itu, populasi yang tidak stunting menyumbang 46.0% dari keseluruhan, dengan jumlah kasus sebanyak 279. Dengan demikian, rasio perbandingan antara balita yang mengalami stunting dibandingkan tidak stunting sudah cukup baik dan setara.



Grafik 5.1 distribusi nilai biner dari variabel target Stunting


Dalam konteks machine learning, variabel yang memiliki korelasi sangat tinggi (biasanya di atas 0.8 atau 0.9) seringkali perlu diwaspadai atau dihindari. Hal ini karena korelasi yang terlalu tinggi antar variabel dapat menyebabkan multikolinearitas, yang dapat mengacaukan interpretasi model, menyebabkan overfitting, dan memperlambat proses pelatihan model (Akoglu, 2018). Oleh karena itu, teknik filter korelasi tinggi sering digunakan untuk mengeliminasi atau menggabungkan variabel yang sangat berkorelasi demi meningkatkan performa dan generalisasi model (Yildirim, 2024). Dalam data stunting, terdapat beberapa variabel yang memiliki hubungan yang cukup kuat dengan kejadian stunting. **Malnutrition Level** (Tingkat Kekurangan Gizi) menunjukkan korelasi positif yang tinggi dengan stunting (0.73), mengindikasikan bahwa terdapat keterkaitan kuat diantara status gizi anak dan risiko stunting. Hal serupa juga terlihat pada variabel **Difficult Access** (Akses yang Sulit) yang berkorelasi positif sedang (0.5), serta diikuti dengan nilai korelasi **Exclusive Milky** (ASI Eksklusif) (0.43). Temuan ini menyoroti bahwa faktor gizi dan akses terhadap layanan atau fasilitas merupakan determinan penting yang terkait erat dengan stunting.



Grafik 5.2 Korelasi Matriks pada Data Stunting


Di sisi lain, beberapa variabel justru menunjukkan korelasi negatif yang lemah dengan stunting. *Healthy_Toilet* (Ketersediaan Toilet Sehat) memiliki korelasi negatif lemah (-0.2), yang menyiratkan bahwa meskipun memiliki arah hubungan yang berlawanan, kekuatan hubungannya tidak kuat. Variabel lain seperti *Smoke Habit* (Kebiasaan Merokok) dan *PureWater Access* (Akses Air Bersih) bahkan menunjukkan korelasi yang sangat lemah dan tidak signifikan (mendekati nol). Namun perlu diketahui, korelasi lemah antara variabel prediktor dengan target bukan berarti variabel tersebut adalah prediktor langsung yang lemah. Korelasi hanya mengukur hubungan linear sederhana dan tidak mencerminkan kontribusi variabel dalam model prediksi multivariat yang kompleks. Variabel dengan korelasi lemah tetap bisa berperan penting sebagai prediktor ketika dikombinasikan dengan variabel lain atau ketika efeknya tidak linier (Manaf, 2022).

Secara keseluruhan, belum ada variabel yang terikat lebih dari 0.8 sehingga belum diperlukan pemenggalan variabel pada data.



Grafik 5.3 Sebaran data tingkat Malnutrisi

Berdasarkan grafik 5.3, distribusi tingkat malnutrisi menunjukkan variasi yang cukup besar di antara kategori yang ada. Tingkat malnutrisi paling dominan adalah Level 1, yang mencakup 37.4% dari total populasi, atau setara dengan 227 kasus. Level 2 menempati posisi kedua dengan proporsi signifikan yaitu 29.0% (176.0 kasus), diikuti oleh tingkat nutrisi normal (level 0) dengan 20.4% (124 kasus) atau $\frac{1}{5}$ dari total data. Level malnutrisi yang lebih tinggi dan ekstrem (Level 3, 4, 5, dan 6) memiliki persentase yang jauh lebih kecil, secara berturut-turut adalah 6.3% (38 kasus), 4.4% (27 kasus), 1.8% (11 kasus), dan Level 6 sebagai yang terkecil hanya 0.7% (4 kasus). Hal ini menyoroti bahwa walaupun malnutrisi tersebar di berbagai tingkat, fokus utama berada pada tingkat Level 1 dan 2 standar WHO. Dapat dibandingkan dengan komparasi pada kasus Stunting.




Grafik 5.4 Perbandingan tingkat Malnutrisi dan kasus stunting

Grafik 5.5 dan 5.6 yang menyajikan hubungan antara status stunting dengan sanitasi (ketersediaan toilet sehat dan akses air bersih) menunjukkan temuan yang menarik mengenai potensi faktor risiko. Mengenai ketersediaan toilet sehat (Healthy_Toilet), terlihat jelas bahwa mayoritas kasus stunting terjadi pada kelompok yang tidak memiliki toilet sehat (kategori 0), di mana terdapat 250 kasus stunting dibandingkan dengan 161 kasus tanpa stunting. Sebaliknya, pada kelompok yang memiliki toilet sehat (kategori 1), kasus stunting menurun signifikan menjadi 78 kasus, dan kasus tanpa stunting berjumlah 118 kasus.



Grafik 5.5 ketersediaan standar toilet sehat pada data


Grafik 5.5 mengindikasikan kepemilikan toilet sehat memiliki hubungan negatif dengan kasus stunting. Ini berarti terdapat peran sanitasi dasar dalam pencegahan stunting. Informasi yang terdapat pada grafik 5.6, kasus stunting tetap mendominasi pada kelompok tidak ada akses air bersih (kategori 0) dengan 187 kasus stunting, namun perbandingannya menjadi lebih seimbang pada kelompok ada akses air bersih (kategori 1). Pada kelompok yang memiliki akses air bersih, jumlah kasus stunting (141) hampir setara dengan jumlah kasus tanpa stunting (144). Sehingga meskipun akses air bersih tetap penting, dampak kepemilikan toilet sehat terlihat lebih ekstrem dalam membedakan kasus stunting dalam sampel responden di KMR.



Grafik 5.6 ketersediaan air bersih pada data

Grafik 5.7 merupakan perbandingan pemberian ASI eksklusif (Exclusive_Milky) dengan status stunting menunjukkan pola anomali. Pada kelompok Tidak Stunting, mayoritas anak (70.3%) tidak diberikan ASI eksklusif (kategori 0), sementara hanya 29.7% yang mendapatkan ASI eksklusif (kategori 1). Pola yang mirip juga terlihat pada kelompok Stunting, di mana proporsi anak yang mendapatkan ASI eksklusif (kategori 1) mencapai 72.6%, berbanding dengan 27.4% yang tidak menerima ASI eksklusif (kategori 0). Perbandingan persentase ini menunjukkan bahwa anak yang stunting didominasi oleh anak yang menerima ASI eksklusif. Sebaliknya, anak yang tidak mengalami stunting didominasi oleh anak yang tidak menerima ASI eksklusif. Hubungan ini menjadi kajian yang menarik karena berbeda

dengan hasil penelitian (Pratama, 2021) yang mengungkapkan bahwa pemberian ASI eksklusif merupakan salah satu faktor proteksi terhadap kejadian stunting pada bayi dan balita.



Grafik 5.7 Perbandingan pemberian ASI Eksklusif pada kasus Stunting


Model XGBoost dengan optimasi TPE

Penelitian ini menggunakan model XGBoost yang telah dioptimasi untuk memprediksi risiko stunting pada balita dengan menerapkan teknik `_extreme_` boosting Classifier dengan berbagai opsi parameter. Berikut ini adalah hasil parameter yang telah optimal via Optuna berdasarkan dataset pelatihan untuk model XGBoost.

No.	parameter	value
1	<code>`alpha`</code>	0.9139587480021765
2	<code>`colsample_bytree`</code>	0.6720470924598951
3	<code>`enable_categorical`</code>	True
4	<code>`gamma`</code>	0.15045909399647112
5	<code>`lambda`</code>	0.4550490817971364
6	<code>`learning_rate`</code>	0.15769956764519155
7	<code>`max_depth`</code>	10
8	<code>`n_estimators`</code>	3217


Untuk parameter yang lain mengikuti konfigurasi default.

Model XGBoost yang digunakan untuk prediksi risiko kasus stunting menunjukkan performa yang berbeda antara kedua kelas. Pada kelas "Tidak Stunting", model cenderung memiliki tingkat sensitifitas (recall) yang sangat tinggi (96.5%), yang berarti model berhasil mengidentifikasi sebagian besar anak yang sebenarnya tidak stunting. Namun, metrik presisi (82.1%) menunjukkan bahwa sekitar 17.9% dari prediksi 'Tidak Stunting' oleh model adalah salah (seharusnya Stunting). Dapat dikatakan model ini cenderung membuat kesalahan dengan mengatakan seseorang tidak stunting padahal sebenarnya stunting. Sehingga kita memperoleh model dengan performa dikhususkan untuk meminimalkan False Negatives (kasus 'Tidak Stunting' yang terlewatkan), yang sering kali diinginkan agar kasus yang sehat tidak salah diklasifikasikan sebagai berisiko stunting, meskipun harus mengorbankan sedikit presisi.



Grafik 5.8 perbandingan metrik pada kelas 'Tidak Stunting' dan 'Stunting'

Sebaliknya, pada kelas "Stunting", model menunjukkan fokus yang berbeda. Tingkat presisi model sangat tinggi, mencapai 96.4%, yang berarti bahwa hampir semua kasus yang diprediksi sebagai 'Stunting' oleh model benar-benar merupakan kasus stunting. Hal ini menunjukkan model sangat konservatif dan reliable ketika memberikan peringatan risiko stunting. Namun, tingkat sensitivitas pada kelas ini lebih rendah sehingga model gagal mengidentifikasi sekitar 18.5% dari total kasus stunting yang sebenarnya (False Negatives). Secara keseluruhan, 'f1-score' yang seimbang tinggi di kedua kelas (88.7% dan 88.3%) menunjukkan bahwa model tersebut adalah pengklasifikasi yang kuat secara keseluruhan. Namun, dari sudut pandang intervensi kesehatan, penurunan sensitivitas pada kelas 'Stunting' adalah poin kritis, karena kasus stunting yang terlewatkan dapat menyebabkan masalah serius pada perkembangan kesehatan balita di daerah KMR.




Grafik 5.9 sebaran pada Confusion Matrix

Confusion Matrix untuk Model XGBoost menunjukkan seberapa baik model membedakan antara status Aktual dan Prediksi stunting. Secara keseluruhan, model ini menunjukkan kinerja klasifikasi yang kuat dengan sebagian besar prediksi berada pada diagonal utama. Jumlah False Negative yang lebih

tinggi ini menunjukkan bahwa model cenderung gagal mendeteksi sejumlah kecil kasus stunting yang sebenarnya, yang berimplikasi pada metrik sensitifitas kelas 'Stunting'. Berdasarkan confusion matrix dari data testing, akurasi model adalah sebesar 88.52%.

Explainable AI

Grafik 5.10 menampilkan tingkat kepentingan relatif (importance score) dari berbagai variabel yang digunakan model untuk memprediksi risiko terkena stunting pada balita. variabel yang paling dominan dan memiliki skor tertinggi adalah 'Difficult_Access' dengan skor 37.8. Hal ini menyiratkan bahwa aksesibilitas atau kesulitan mencapai layanan kesehatan adalah prediktor tunggal yang paling kuat untuk membedakan status stunting. Diikuti dengan variabel 'Malnutrition_Level' dengan skor 37.0, yang menunjukkan bahwa tingkat malnutrisi yang sudah ada juga sangat penting dalam model prediksi. Selanjutnya ditempati oleh 'Exclusive_Milky' (pemberian ASI eksklusif) dengan skor 35.2, memperjelas bahwa meskipun data ASI eksklusif sebelumnya menunjukkan korelasinya lemah, model XGBoost saat ini menganggap ketiga variabel tersebut sebagai faktor diskriminatif yang utama. Tiga variabel teratas ini secara kolektif mendominasi prediksi model, menunjukkan bahwa masalah logistik/akses, status gizi yang sudah ada, dan praktik pemberian makan adalah inti dari pemodelan stunting.



Grafik 5.10 Variabel penting dari model XGBoost


Kelompok variabel selanjutnya mencakup faktor lingkungan, kebiasaan, dan demografi. Variabel 'District_Code' berada di posisi keempat dengan skor 31.1, menegaskan bahwa lokasi geografis distrik memberikan informasi unik yang besar dalam memprediksi risiko stunting, kemungkinan besar karena perbedaan kebijakan, logistik obat-obatan/makanan atau kondisi luas lingkungan pada wilayah distrik terkait. Terdapat gap yang cukup besar terjadi dibawah District_code. Secara harfiah, dapat diinterpretasikan sebagai bentuk dari segment importance pada model. Variabel 'Smoke_Habit' (kebiasaan merokok dalam rumah tangga) juga penting dengan skor 22.0, menyoroti dampak kesehatan lingkungan dan kebiasaan. Menariknya, dua variabel sanitasi yang sebelumnya dianalisis, yaitu 'PureWater_Access' dan 'Healthy_Toilet', meskipun dalam beberapa penelitian memiliki hubungan yang jelas dengan kasus stunting, skor importance-nya relatif lebih rendah, masing-masing 17.2 dan 15.2, dibandingkan dengan variabel lainnya. Variabel 'Gender' memiliki skor terendah di antara semua variabel (13.5), sehingga bisa diinterpretasikan tidak ada diskriminatif yang jelas antara jenis kelamin laki-laki dan perempuan pada balita untuk terpapar risiko stunting di KMR. Meskipun dalam beberapa penelitian, sanitasi dalam keluarga itu penting dalam mengurangi risiko stunting (Pratama, 2021), variabel akses/logistik dan tingkat gizi lain lebih krusial dalam kemampuan diskriminasi model XGBoost untuk memprediksi risiko stunting di KMR.

Kita ambil contoh 3 baris data untuk menunjukkan grafik Local Force Explanation pada grafik SHapley Additive exPlanations (SHAP) yakni jawaban responden 10, 12, dan 13 dari data testing berdasarkan dokumentasi dari Lundberg (2018). Untuk informasi data pada baris tersebut, dapat dilihat pada grafik 5.11.

	District_Code	Gender	Malnutrition_Level	Exclusive_Milky	Smoke_Habit	PureWater_Access	Healthy_Toilet	Difficult_Acess
10	10	1	3	1	0	1	0	1
12	6	1	1	0	0	1	1	0
13	1	1	2	1	0	1	0	1


Grafik 5.11 Data hasil informasi dari responden 10, 12 dan 13 di KMR

Interpretasi SHAP untuk responden ke-10 pada grafik 5.12 menunjukkan model XGBoost membuat prediksi pasti (dengan probabilitas mencapai 1.0) untuk status Stunting. Keputusan kuat ini didominasi oleh variabel Tingkat Malnutrisi dengan nominal 3, memberikan kontribusi terbesar (0.56) ke arah Stunting, menggarisbawahi bahwa kondisi gizi yang sudah parah adalah prediktor utama. Selain itu, faktor lingkungan dan logistik seperti Akses Sulit juga berkontribusi secara signifikan pada prediksi Stunting. Meskipun individu ini menerima ASI Eksklusif (nilai 1), efek positifnya terhadap pencegahan stunting sangat kecil (0.03) dan jauh dibawah faktor risiko malnutrisi dan akses yang sulit.



Grafik 5.12 SHAP pada responden ke-10 pada data testing


Analisis kasus responden ke-10 memperkuat bahwa kombinasi kondisi gizi yang kritis dan hambatan infrastruktur kesehatan/logistik adalah kontributor utama status stunting. Meskipun beberapa variabel (seperti Toilet Sehat yang bernilai 0 dan Kebiasaan Merokok 0) memberikan kontribusi minor ke arah 'Tidak Stunting', pengaruhnya tidak signifikan untuk membalikkan prediksi.



Grafik 5.13 SHAP pada responden ke-12 pada data testing

Kemudian, untuk responden ke-12 pada grafik 5.13 menunjukkan bahwa model XGBoost menunjukkan keputusan diskriminatif yang jelas ke arah Tidak Stunting dengan probabilitas 0.93. Keputusan model ini didominasi oleh nilai variabel Tingkat Malnutrisi ringan dengan nominal 1, memberikan kontribusi terbesar (0.84) ke arah 'Tidak Stunting'. Selain itu, dari faktor lingkungan dan kebiasaan yang menguntungkan, yaitu pemberian ASI Eksklusif (nilai 1) dan ketiadaan kebiasaan merokok (nilai 0), serta Tidak Adanya Akses Sulit mendukung keputusan model. Meskipun terdapat beberapa variabel yang mendorong sedikit ke arah Stunting, seperti akses air bersih bernilai 1 yang diinterpretasikan model sebagai kontributor minor ke arah stunting dan kepemilikan toilet sehat yang bernilai 1, kontribusi dari faktor-faktor ini tidak signifikan. Selanjutnya, rendahnya tingkat malnutrisi


yang ada dan kombinasi lingkungan yang mendukung (termasuk tidak adanya kesulitan akses) menjadi penentu utama status Tidak Stunting dalam kasus ini.



Grafik 5.14 SHAP pada responden ke-13 pada data testing


Pada responden ke-13 dari grafik 5.14, model XGBoost kembali membuat prediksi yang sangat tegas ke risiko Stunting dengan probabilitas 1.00. Prediksi ini hampir sepenuhnya didorong oleh Tingkat Malnutrisi yang bernilai 2 (malnutrisi sedang), memberikan kontribusi utama ke arah Stunting dengan nilai SHAP 0.69. Faktor pendukung lain yang mendorong Stunting adalah pemberian ASI Eksklusif bernilai 1 (diberikan) dan Akses Air Bersih bernilai 1, meskipun kontribusi nilai SHAP dari variabel-variabel ini sangat kecil (0.05 dan 0.02). Sementara itu, ketiadaan toilet sehat (Healthy_Toilet bernilai 0) dan ketiadaan kebiasaan merokok (Smoke_Habit bernilai 0) adalah faktor yang memberikan sedikit kontribusi ke arah 'Tidak Stunting', namun kontribusi gabungannya tidak mampu mengimbangi dominasi kuat dari faktor Tingkat Malnutrisi dan Akses Sulit yang bernilai 1 yang menguatkan prediksi Stunting.

Adanya kontribusi dari variabel Tingkat Malnutrisi yang sangat mayoritas, mengakibatkan kontribusi dari variabel penjelas yang lainnya kurang nampak. Kami mencoba untuk meniadakan variabel penjelasan "Malnutrition_Level" pada data training, sehingga hal ini akan berdampak pada hasil model. Dan hasil analisis outputnya, kami gunakan explainable AI seperti sebelumnya sehingga menjadi seperti grafik 5.15, 5.16, dan 5.17.




Grafik 5.12 SHAP pada responden ke-10 pada data testing tanpa "Malnutrition_Level"

Dengan meniadakan variabel Tingkat Malnutrisi dari data training model, prediksi untuk responden ke-10 menjadi Stunting dengan probabilitas 0.84 (menurun dari 1.00 pada model awal), menunjukkan bahwa variabel lain mengambil alih peran prediktif. Tanpa adanya variabel gizi yang paling dominan, faktor Akses Sulit (bernilai 1) menjadi kontributor utama Stunting dengan nilai SHAP 0.32. Disusul oleh faktor-faktor lain seperti Kode Distrik 10 (0.23) dan Pemberian ASI Eksklusif (Exclusive_Milky bernilai 1) (0.21), yang bersama-sama menegaskan bahwa hambatan logistik dan lingkungan spesifik distrik menjadi kontributor utama prediksi stunting. Sementara itu, variabel-variabel seperti ketiadaan kebiasaan merokok (Smoke_Habit bernilai 0) dan ketiadaan Toilet Sehat (Healthy_Toilet bernilai 0) memberikan kontribusi minor ke arah 'Tidak Stunting', namun tidak cukup kuat untuk menandingi dampak kumulatif dari akses sulit, lokasi, dan ASI eksklusif, yang kini menjadi variabel risiko paling menonjol.




Grafik 5.13 SHAP pada responden ke-12 pada data testing tanpa "Malnutrition_Level"

Hal yang sama juga dilakukan untuk data responden ke-12 dan ke-13 dari data testing pada grafik 5.13 dan 5.14 secara berurutan. Hanya terlihat sedikit perbedaan angka kontribusi diantara variabel-variabel penjelas kepada model. Terdapat peningkatan kontribusi namun tingkat kontribusinya untuk keputusan model masih sama. Dan dari model XGBoost sendiri memberikan hasil diskriminatif yang sama terkait dengan risiko stunting.



Grafik 5.14 SHAP pada responden ke-13 pada data testing tanpa "Malnutrition_Level"

Pada Grafik 5.15 yang menunjukkan bagaimana setiap variabel secara keseluruhan memengaruhi prediksi model, serta distribusi dampaknya pada output model. Setiap baris mewakili satu variabel prediktor, dan warna menunjukkan nilai variabel (biru untuk nilai variabel yang rendah dan merah untuk nilai variabel yang tinggi). variabel yang paling dominan dalam memengaruhi prediksi adalah Tingkat Malnutrisi. Nilai Malnutrisi yang tinggi (merah) memiliki dampak positif yang sangat besar (Nilai SHAP tinggi, ke kanan), mendorong prediksi ke arah Stunting, sedangkan nilai Malnutrisi yang rendah (biru) memiliki dampak negatif yang besar (Nilai SHAP rendah, ke kiri), mendorong prediksi ke arah Tidak Stunting. Pola yang jelas dan terpisah ini mengonfirmasi bahwa Tingkat Malnutrisi adalah variabel yang paling berkontribusi dan diskriminatif dalam model XGBoost. Untuk variabel lain yang juga memberikan kontribusi mayoritas dan menunjukkan pola yang mirip adalah Pemberian ASI Eksklusif dan Kode Distrik (yang merujuk pada kebijakan distrik terkait), yang nilai-nilai variabelnya juga tersebar luas pada sumbu SHAP.



Grafik 5.15 SHAP Summary plot dari model XGBoost

Namun perlu diketahui, meskipun masih penting, variabel-variabel tersebut menunjukkan dampak yang lebih terpusat di sekitar nilai SHAP nol, mengindikasikan dampak rata-rata yang lebih kecil atau kurang konsisten terhadap output model. Misalnya, Kebiasaan Merokok dan Toilet Sehat menunjukkan distribusi nilai SHAP yang lebih padat di tengah, meskipun nilai variabel yang tinggi (merah) cenderung mendorong prediksi ke arah Stunting (SHAP positif) dan nilai variabel rendah (biru) mendorong ke arah Tidak Stunting (SHAP negatif). Dua variabel dengan dampak terkecil adalah Akses Air Bersih dan Akses Sulit, yang titik-titiknya sangat terkonsentrasi di dekat nol.

Terdapat perbedaan interpretasi diantara SHAP summary plot (grafik 5.15) dengan feature importance pada grafik 5.10 dimana variabel "Akses Sulit" menunjukkan perbedaan tingkat kontribusi. Hal ini disebabkan karena feature importance dan SHAP value mengukur aspek yang berlainan. Dalam feature importance XGBoost, Akses Sulit menempati posisi penting (nilai 17.2), yang mengindikasikan bahwa fitur ini secara konsisten digunakan oleh model untuk memecah data dan membangun struktur pohon keputusan menggunakan data training. Namun, dalam SHAP summary plot, dampak rata-ratanya terhadap output prediksi stunting relatif lebih kecil menggunakan data testing. Hal ini menunjukkan bahwa meskipun Akses Sulit sering menjadi pembeda dalam model, pengaruh langsungnya terhadap pergeseran skor risiko stunting tidak sekuat yang disarankan oleh feature importance-nya, kemungkinan karena efeknya bersifat tidak langsung atau termoderasi oleh variabel mediator lainnya.

	51
Stunting	0
Gender	0
Malnutrition_Level	0
Exclusive_Milky	1
Smoke_Habit	0
PureWater_Access	0
Healthy_Toilet	0
Difficult_Acess	1

Grafik 5.16 Data responden ke-51 pada data testing

Grafik SHAP Force Plot adalah visualisasi yang menunjukkan kontribusi setiap fitur secara individual terhadap prediksi model untuk satu instance/sampel tertentu. Grafik 5.17 untuk responden ke-51 menunjukkan bahwa model XGBoost memprediksi status Tidak Stunting (lower) dengan nilai output -1.21, yang berada di bawah base value 1.469. Penurunan prediksi ini didorong kuat oleh dua faktor utama: Tingkat Malnutrisi yang bernilai 0 (tingkat paling rendah/sehat) memberikan kontribusi terbesar ke kiri (Tidak Stunting), dan pemberian ASI Eksklusif yang bernilai 1 juga memberikan kontribusi signifikan ke arah 'lower'. Namun, terdapat faktor-faktor yang bekerja sebaliknya, mendorong prediksi ke arah Stunting (higher), yaitu ketiadaan Toilet Sehat (bernilai 0), ketiadaan Akses Air Bersih (bernilai 0), dan ketiadaan kebiasaan merokok (bernilai 0), di mana variabel 0 secara anomali diinterpretasikan model sebagai kontributor kecil ke arah Stunting. Meskipun demikian, kontribusi kuat dari Tingkat Malnutrisi yang sangat rendah dan pemberian ASI Eksklusif dengan jelas mendominasi, sehingga menghasilkan prediksi akhir yang kuat untuk status Tidak Stunting.



Grafik 5.17 SHAP force plot untuk responden ke-51

Grafik SHAP Force Plot untuk responden ke-108 pada 5.19 menunjukkan bahwa model XGBoost memprediksi status Tidak Stunting (lower) dengan nilai output -2.15, yang merupakan prediksi kuat ke arah "Tidak Stunting" karena jauh di bawah base value 1.469. kontribusi utama untuk prediksi ini datang dari Tingkat Malnutrisi yang bernilai 1 (tingkat rendah/ringan) dan ketiadaan pemberian ASI Eksklusif (bernilai 0), di mana variabel ASI Eksklusif yang bernilai nol secara anomali diinterpretasikan oleh model sebagai kontributor kuat ke arah 'Tidak Stunting' (efek positif dari tidak adanya variabel tersebut). Faktor-faktor yang berusaha mendorong prediksi ke arah Stunting (higher) adalah kebiasaan merokok (bernilai 1) dan ketiadaan Toilet Sehat (bernilai 0). Namun, kontribusi negatif yang sangat besar dari Malnutrisi Level 1 dan faktor ASI Eksklusif yang tidak diberikan, berhasil mengatasi kontribusi risiko dari kebiasaan merokok dan sanitasi yang buruk, sehingga menghasilkan prediksi akhir yang kuat untuk status Tidak Stunting.

108

Stunting	0
Gender	0
Malnutrition_Level	1
Exclusive_Milky	0
Smoke_Habit	1
PureWater_Access	1
Healthy_Toilet	0
Difficult_Acess	1

dtype: int64

Grafik 5.18 Data responden ke-108



Grafik 5.19 SHAP force plot untuk responden ke-108

KESIMPULAN DAN SARAN

Analisis data stunting pada KMR tahun 2024 menunjukkan bahwa pembagian kelas stunting dan tidak stunting relatif seimbang dengan proporsi masing-masing sebesar 54,0% dan 46,0%. Korelasi variabel menunjukkan bahwa tingkat malnutrisi, kesulitan akses layanan kesehatan, dan pemberian ASI eksklusif merupakan prediktor utama yang berhubungan erat dengan risiko stunting. Sementara variabel sanitasi dasar seperti ketersediaan toilet sehat dan akses air bersih menunjukkan hubungan negatif atau korelasi lemah, peran faktor lingkungan dan logistik tetap penting dalam konteks prediksi dan pencegahan stunting.

Model XGBoost dengan optimasi TPE yang dikembangkan memberikan performa klasifikasi yang baik dengan akurasi mencapai 88,52%. Model ini unggul dalam mengidentifikasi anak yang tidak stunting dengan tingkat recall tinggi namun masih menghadapi tantangan pada sensitivitas kelas stunting, dimana sekitar 18,5% kasus stunting tidak terdeteksi. Analisis Explainable AI mengungkapkan variabel 'Difficult_Access', 'Malnutrition_Level', dan 'Exclusive_Milky' sebagai fitur paling dominan dalam memprediksi risiko stunting, sementara faktor distrik dan kebiasaan merokok juga memberikan kontribusi penting, meskipun sanitasi memiliki kontribusi yang lebih kecil di dalam model.

Interpretasi model menggunakan SHAP menjelaskan bahwa tingkat malnutrisi adalah kontributor paling kuat terhadap prediksi status stunting, diikuti oleh faktor akses layanan kesehatan dan pemberian ASI eksklusif. Eksperimen penghapusan fitur tingkat malnutrisi menegaskan bahwa tanpa variabel ini, fitur terkait hambatan akses dan kondisi lingkungan distrik mengambil peran utama sebagai prediktor risiko. Temuan ini menyoroti pentingnya kombinasi faktor gizi dan hambatan logistik dalam strategi intervensi pencegahan stunting di wilayah KMR. Lebih lanjut, analisis SHAP force plot pada level individu mengungkap mekanisme yang lebih detail tentang kontribusi Akses Sulit. Pada responden dengan prediksi stunting, kombinasi antara Akses Sulit dan tingkat malnutrisi yang tinggi menjadi faktor pendorong dominan, sementara pada kasus tidak stunting, ketiadaan Akses Sulit bersama dengan tingkat malnutrisi rendah justru memberikan kontribusi protektif. Pola ini menegaskan bahwa Akses Sulit beroperasi melalui interaksi yang kompleks dengan variabel lain, khususnya status gizi, dimana pengaruhnya menjadi signifikan ketika dikombinasikan dengan faktor risiko lainnya.

Secara keseluruhan, temuan ini menyoroti bahwa meskipun Akses Sulit merupakan prediktor penting dalam model, interpretasi kontribusinya memerlukan pendekatan multi-dimensional. Penting untuk mempertimbangkan baik pentingnya struktural dalam model (seperti yang terlihat dalam feature importance) maupun dampak aktualnya terhadap prediksi (seperti yang diukur oleh SHAP values), serta interaksinya dengan determinan stunting lainnya, untuk memahami secara komprehensif peran Akses Sulit dalam memprediksi risiko stunting pada populasi yang diteliti.

Untuk itu, intervensi untuk menurunkan stunting sebaiknya difokuskan pada perbaikan gizi dan aksesibilitas rumah sakit/puskesmas, sementara faktor lingkungan lain mungkin memerlukan investigasi lebih lanjut.

REFERENCES

1. Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '19)*, 2623–2631. <https://doi.org/10.1145/3292500.3330701>.
2. Akoglu, Haldun. (2018). User's guide to correlation coefficients. *Turkish Journal of Emergency Medicine*, 18(3), 91–93. <https://doi.org/10.1016/j.tjem.2018.08.001>.

3. Bergstra, J., Yamins, D., & Cox, D. D. (2013). Making a Science of Model Search: Hyperparameter Optimization in Hundreds of Dimensions for Vision Architectures. *Proceedings of the 30th International Conference on Machine Learning (ICML-13)*, 115–123.
4. Cenderawasih Pos. (2024). Tertinggi di Papua, Kasus Prevalensi Stunting di Mamberamo Raya Capai 40. <https://cenderawasihpos.jawapos.com/pariwara/20/12/2024/tertinggi-di-papua-kasus-prevalensi-stunting-di-mamberamo-raya-capai-40>.
5. Chen, T., & Guestrin, C. (2025). Introduction to Boosted Trees. XGBoost Documentation. Diakses dari <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>.
6. Chilyabanyama, O. N., Chilengi, R., Simuyandi, M., Chisenga, C. C., Chirwa, M., Hamusonde, K., Saroj, R. K., Iqbal, N. T., Ngaruye, I., & Bosomprah, S. (2022). Performance of Machine Learning Classifiers in Classifying Stunting among Under-Five Children in Zambia. *Children*, 9(7), 1082. <https://doi.org/10.3390/children9071082>.
7. Kementerian Kesehatan Republik Indonesia. (2022). Buku Saku Survei Status Gizi Indonesia (SSGI) 2022. <https://repository.badankebijakan.kemkes.go.id/id/eprint/4855/3/Buku%20Saku%20SSGI%202022%20rev%20270123%20OK.pdf>.
8. Kementerian Kesehatan Republik Indonesia. (2023). Survei Kesehatan Indonesia 2023 Dalam Angka Status Gizi Indonesia (SSGI) 2022. pp 924. [https://kemkes.go.id/app_asset/file_content_download/17169067256655eae5553985.98376730.pdf](https://kemkes.go.id/app_asset/file_content_download/17169067256655eae5553985.98376730.pdf).
9. Kusumawati, E., Rahardjo, S., & Sari, H. P. (2015). Model Pengendalian Faktor Risiko Stunting pada Anak Bawah Tiga Tahun. *Kesmas*, 9(3), Artikel 8. Diakses dari <https://scholarhub.ui.ac.id/kesmas>.
10. Lundberg, Scott. (2018). ****SHAP documentation****. Diakses dari <https://shap.readthedocs.io/en/latest/overviews.html>.
11. Manaf, S. A. R., Erfiani, Indahwati, Fitrianto, A., & Amelia, R. (2022). Faktor – Faktor yang Memengaruhi Permasalahan Stunting di Jawa Barat Menggunakan Regresi Logistik Biner. *Jurnal Statistika*, 15(2), 265–274.
12. Muhdar, M., Rosmiati, R., Tulak, G. T., Saputri, E., & Susanti, R. W. (2022). Peran Petugas Kesehatan dalam Pencegahan dan Penanganan Stunting di Kabupaten Kolaka. *Jurnal Kesehatan Andalas*, 11(1). <https://doi.org/10.25077/jka.v11i1.1930>.
13. Murdiansyah, D. T. (2024). Prediksi Stroke Menggunakan Extreme Gradient Boosting. *JIKO (Jurnal Informatika dan Komputer)*, 8(2), 419–426. <https://doi.org/10.26798/jiko.v8i2.1295>.
14. Peta Tematik Indonesia. (2014). Administrasi Kabupaten Mamberamo Raya. Diakses dari [<https://petatematikindo.wordpress.com/2014/08/14/administrasi-kabupaten-mamberamo->

raya](<https://petatematikindo.wordpress.com/2014/08/14/administrasi-kabupaten-memberamo-raya>).

15. Pratama, M. R., & Irwandi, S. (2021). HUBUNGAN PEMBERIAN ASI EKSKLUSIF DENGAN STUNTING DI PUSKESMAS HINAI KIRI, KECAMATAN SECANGGANG, KABUPATEN LANGKAT. *Jurnal Saintika Medika*, *4*(1). <https://doi.org/10.30743/stm.v4i1.65>.
16. Shen, H., Zhao, H., & Jiang, Y. (2023). Machine Learning Algorithms for Predicting Stunting among Under-Five Children in Papua New Guinea. *Children*, 10(10), 1638. <https://doi.org/10.3390/children10101638>.
17. Sugihartono, T., Wijaya, B., Marini, Alkayes, A. F., & Anugrah, H. A. (2025). Optimizing Stunting Detection through SMOTE and Machine Learning: a Comparative Study of XGBoost, Random Forest, SVM, and k-NN. *Journal of Applied Data Sciences*, 6(1), 667-682. <https://doi.org/10.47738/jads.v6i1.494>.
18. Tribuana, D., Baharuddin, & Resky, A. M. (2025). Penerapan Algoritma XGBoost untuk Prediksi Kepuasan Pelanggan pada Layanan E-Commerce: Studi pada Dataset Transaksi Nyata. *JTBC: Jurnal Teknologi dan Bisnis Cerdas*, 1(1), Juni 2025. e-ISSN 3109-8924. <https://doi.org/10.64476/jtbc.v1i1.5>.
19. Wicaksono, A., Prasetyo, D., Mar'atullatifah, Y., Iswavigra, D. U., Mahmudah, H., & Hapsari, A. (2025). Data Analysis and Explainable Machine Learning for Stunting Prediction. *Journal of Artificial Intelligence and Legal Technology*, 1(1).
20. Yildirim, Hasan. (2024). The Multicollinearity Effect on the Performance of Machine Learning Algorithms: Case Examples in Healthcare Modelling. *Asian Pacific Journal of Education, Sport and Science*, 12(3), 68-80. <https://doi.org/10.21541/apjess.1371070>.
21. Yulianti, S. E. H., Soesanto, O., & Sukmawaty, Y. (2022). Penerapan Metode Extreme Gradient Boosting (XGBOOST) pada Klasifikasi Nasabah Kartu Kredit. *OMTA Journal of Mathematics: Theory and Applications*, 4(1), 21. P-ISSN 2685-9653, e-ISSN 2722-2705.